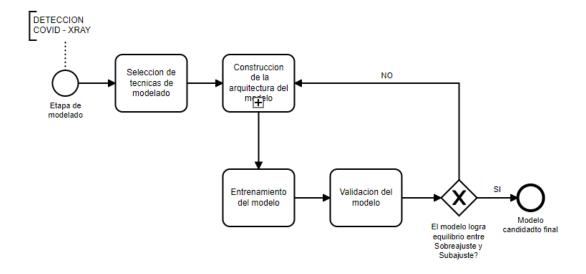
Modelado usando Transfer Learning con DenseNet169 y balanceo por Penalización de clases

August 29, 2021

Esta fase de la metodologia consiste en extraer el valor de los datos desarrollando un modelo que aprenda de los patrones en estos.

• El diagrama en cuestion de esta fase esta a continuacion:



```
[1]: import tensorflow as tf
from tensorflow.keras.utils import plot_model
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from tensorflow.keras.preprocessing.image import ImageDataGenerator #generator

→ de imagenes
from sklearn.utils import class_weight
from sklearn.metrics import classification_report
import random
```

[2]: tf.keras.backend.clear_session()

```
[3]: tf.random.set_seed(42) #semilla 42, para la reproducibilidad de resultados random.seed(42)
np.random.seed(42)
```

0.0.1 Canalización de datos

• Preparamos la canalización de datos, a partir de las imagenes del disco.

```
[4]: train_datagen=ImageDataGenerator(
                 rescale=1.0/255, #escalamos los datos en rangos de [-1,1] El modelo⊔
      →MobileNetv2 espera esta configuracion
                 rotation_range = 45,
                 zoom range = 0.2,
                 shear_range = 0.2,
                 width_shift_range = 0.2,
                 height_shift_range = 0.2,
                 horizontal_flip=True,
                 vertical_flip = True,
                 fill_mode = 'nearest'
     #sobre los datos de validación y test no se hace ningun aumento de datos.
     validation_datagen=ImageDataGenerator(rescale=1.0/255) #escalamiento de_u
      →validacion a un rango de [0,1]
                                                            #escalamiento de test a⊔
     test_datagen=ImageDataGenerator(rescale=1.0/255)
      \rightarrowun rango de [0,1]
```

```
[5]: #definimos las rutas para el acceso a los datos
     train_path="../input/datasetv3/Datasets/train"
     validation_path="../input/datasetv3/Datasets/val"
     test_path="../input/datasetv3/Datasets/test"
     #creamos los generadores de datos a partir de los flujos de informacion
     BATCH_SIZE=32 #tamaño del lote que se ira pasando poco a poco
     IMAGE_SIZE=(256,256)
     train_generator=train_datagen.flow_from_directory(
         train path,
         target_size=IMAGE_SIZE,
         batch_size=BATCH_SIZE,
         class_mode="categorical"
     )
     validation_generator=validation_datagen.flow_from_directory(
         validation_path,
         target_size=IMAGE_SIZE,
         batch_size=BATCH_SIZE,
         class mode="categorical"
```

```
test_generator=test_datagen.flow_from_directory(
    test_path,
    target_size=IMAGE_SIZE,
    batch_size=BATCH_SIZE,
    class_mode="categorical"
)
```

```
Found 15238 images belonging to 3 classes. Found 1694 images belonging to 3 classes. Found 4233 images belonging to 4 classes.
```

0.0.2 Tecnica para el tratamiento de datos Desbalanceados. Penalización por pesos de clases

penalizando los pesos de las clases mayoritarias a favor de las clases minoritarias.

```
[6]: from sklearn.utils import class_weight

classes=train_generator.classes

class_weights=class_weight.compute_class_weight("balanced",np.

ounique(classes),classes)
```

/opt/conda/lib/python3.7/site-packages/sklearn/utils/validation.py:70:
FutureWarning: Pass classes=[0 1 2], y=[0 0 0 ... 2 2 2] as keyword args. From version 0.25 passing these as positional arguments will result in an error FutureWarning)

```
[7]: class_weights=dict(enumerate(class_weights))
print("Los pesos son {0}".format(class_weights))
```

```
Los pesos son {0: 1.950588837685612, 1: 0.9590886203423967, 2: 0.6921958753520487}
```

0.0.3 Selección de tecnicas de Modelado

Al tratarse de un problema de clasificacion de imagenes entre los posibles candidatos tenemos:

- MultiLayer Pereptron: Red neuronal de capas densamente conectadas
- Convolutional Neuronal Network: Red neuronal convolucional.
- Modelos de machine learning clasico (Maquinas de soporte vectorial, arboles de decision e impulso, etc.)

Escogi la red neuronal convolucional porque **aprende de patrones locales** como rasgos pequeños y en bloques de informacion, mientras que el **MLP** aprende de patrones específicos, e decir de todo el espacio de entrada en general.

0.0.4 Construcción de la arquitectura del modelo

- Para la construccion de la arquitectura crearemos un modelo con transferencia de aprendizaje con una arquitectura de red neuronal solida.
- Generando Callbacks para detener el entrenamiento cuando no se tienen buenos resultados

1 Aplicación de Transfer Learning usando DenseNet169 y tecnica de anti-desbalanceo Penalización de clases

• Se escogio la arquitectura DenseNet169 por tener un mayor precision sobre el conjunto de datos Image.net en la que fue entrenado.

```
[9]: INPUT_SHAPE=(256,256,3)
     BASE_LEARNING_RATE=0.0001
     def build_model_transferLearning():
         dense_net169=tf.keras.applications.DenseNet169(
                     weights="imagenet",
                     input_shape=INPUT_SHAPE,
                     include_top=False
                 )
         #descongelamos algunas capas
         dense net169.trainable=False
         for layer in dense net169.layers:
             if 'conv5' in layer.name:
                 layer.trainable=True
             else:
                 layer.trainable=False
         #creamos el modelo
         inputs=tf.keras.Input(shape=INPUT_SHAPE)
         x=dense_net169(inputs)
         x=tf.keras.layers.Flatten()(x)
         x=tf.keras.layers.BatchNormalization()(x)
         x=tf.keras.layers.Dense(256,activation="relu")(x)
         x=tf.keras.layers.Dropout(0.4)(x)
         x=tf.keras.layers.BatchNormalization()(x)
         x=tf.keras.layers.Dense(128,activation="relu")(x)
         x=tf.keras.layers.Dropout(0.4)(x)
```

```
outputs=tf.keras.layers.Dense(3,activation="softmax")(x)

model=tf.keras.Model(inputs,outputs)

model.compile(
    optimizer=tf.keras.optimizers.Adam(learning_rate=BASE_LEARNING_RATE),
    loss="categorical_crossentropy",
    metrics=[
        tf.keras.metrics.CategoricalAccuracy(name="accuracy"),
        tf.keras.metrics.Recall(name="recall")
    ]
)
return model
```

[10]: transfer_model=build_model_transferLearning()

[11]: transfer_model.summary()

Model: "model"

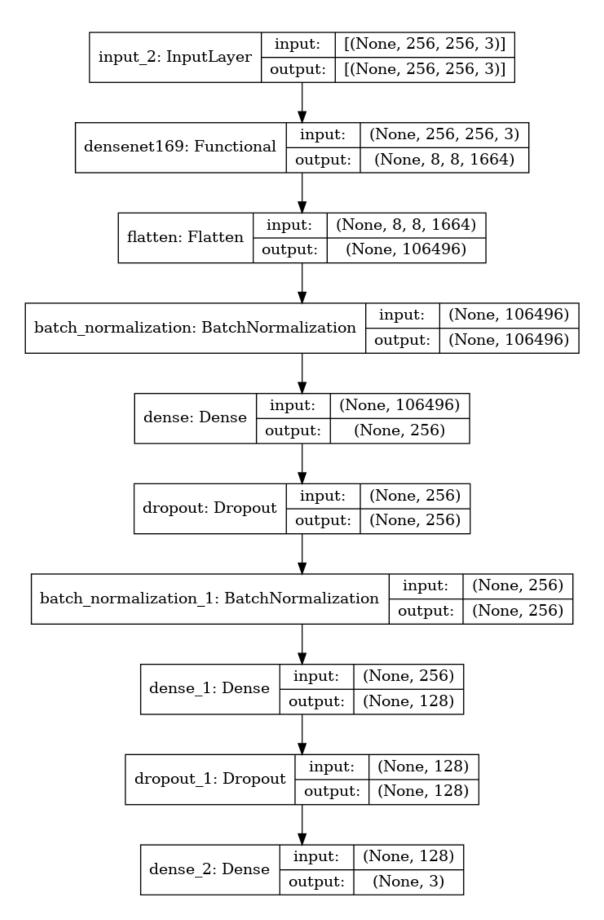
Layer (type)	Output Shape	Param #
input_2 (InputLayer)	[(None, 256, 256, 3)]	0
densenet169 (Functional)	(None, 8, 8, 1664)	12642880
flatten (Flatten)	(None, 106496)	0
batch_normalization (BatchNo	(None, 106496)	425984
dense (Dense)	(None, 256)	27263232
dropout (Dropout)	(None, 256)	0
batch_normalization_1 (Batch	(None, 256)	1024
dense_1 (Dense)	(None, 128)	32896
dropout_1 (Dropout)	(None, 128)	0
dense_2 (Dense)	(None, 3)	387

Total params: 40,366,403

Trainable params: 33,423,619
Non-trainable params: 6,942,784

[12]: plot_model(transfer_model, "transfer_densenet.png", show_shapes=True)

[12]:



ENTRENAMIENTO DEL MODELO

• El entrenamiento se realiza en **100 epocas**, un generador de datos de entrenamiento, un generador de datos de validacion, 2 callbacks para detener el entrenamiento de manera temprana en caso no se obtengan buenos resultados en base a la funcion de perdida en los datos de validacion durante 10 epocas consecutivas, y otra para guardar por puntos el mejor modelo obtenido hasta el momento.

```
Epoch 1/100
accuracy: 0.6627 - recall: 0.6296 - val_loss: 0.5108 - val_accuracy: 0.7969 -
val_recall: 0.7825
Epoch 2/100
accuracy: 0.7942 - recall: 0.7743 - val_loss: 0.3638 - val_accuracy: 0.8588 -
val_recall: 0.8504
Epoch 3/100
477/477 [============= ] - 238s 494ms/step - loss: 0.4465 -
accuracy: 0.8305 - recall: 0.8121 - val loss: 0.3318 - val accuracy: 0.8870 -
val recall: 0.8678
Epoch 4/100
accuracy: 0.8566 - recall: 0.8420 - val loss: 0.3582 - val accuracy: 0.8576 -
val_recall: 0.8438
Epoch 5/100
accuracy: 0.8563 - recall: 0.8440 - val_loss: 0.3558 - val_accuracy: 0.8588 -
val_recall: 0.8486
Epoch 6/100
accuracy: 0.8711 - recall: 0.8596 - val_loss: 0.2772 - val_accuracy: 0.9002 -
val_recall: 0.8912
```

```
Epoch 7/100
477/477 [============= ] - 237s 491ms/step - loss: 0.3295 -
accuracy: 0.8712 - recall: 0.8580 - val_loss: 0.2741 - val_accuracy: 0.9038 -
val recall: 0.8930
Epoch 8/100
accuracy: 0.8792 - recall: 0.8682 - val_loss: 0.2921 - val_accuracy: 0.8930 -
val_recall: 0.8840
Epoch 9/100
477/477 [============= ] - 234s 484ms/step - loss: 0.2877 -
accuracy: 0.8868 - recall: 0.8761 - val loss: 0.2601 - val accuracy: 0.9062 -
val_recall: 0.9026
Epoch 10/100
accuracy: 0.8905 - recall: 0.8827 - val_loss: 0.2395 - val_accuracy: 0.9093 -
val_recall: 0.9014
Epoch 11/100
477/477 [============= ] - 231s 478ms/step - loss: 0.2734 -
accuracy: 0.8948 - recall: 0.8848 - val_loss: 0.2476 - val_accuracy: 0.9069 -
val recall: 0.9008
Epoch 12/100
accuracy: 0.8989 - recall: 0.8909 - val_loss: 0.2741 - val_accuracy: 0.8978 -
val_recall: 0.8936
Epoch 13/100
477/477 [============ ] - 235s 484ms/step - loss: 0.2690 -
accuracy: 0.8937 - recall: 0.8862 - val_loss: 0.2466 - val_accuracy: 0.9147 -
val_recall: 0.9129
Epoch 14/100
477/477 [============== ] - 234s 484ms/step - loss: 0.2608 -
accuracy: 0.8998 - recall: 0.8940 - val_loss: 0.2942 - val_accuracy: 0.8918 -
val_recall: 0.8888
Epoch 15/100
accuracy: 0.9051 - recall: 0.8991 - val loss: 0.2441 - val accuracy: 0.9087 -
val recall: 0.9056
Epoch 16/100
accuracy: 0.9033 - recall: 0.8981 - val_loss: 0.2478 - val_accuracy: 0.9099 -
val_recall: 0.9069
Epoch 17/100
accuracy: 0.9124 - recall: 0.9052 - val_loss: 0.2949 - val_accuracy: 0.8948 -
val recall: 0.8900
Epoch 18/100
accuracy: 0.9183 - recall: 0.9131 - val_loss: 0.2675 - val_accuracy: 0.8996 -
val_recall: 0.8936
```

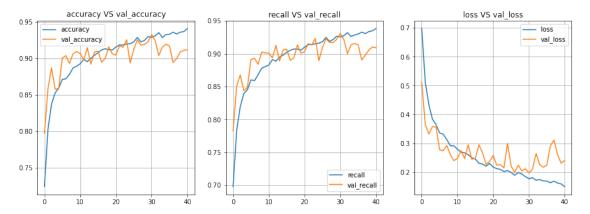
```
Epoch 19/100
477/477 [============= ] - 237s 491ms/step - loss: 0.2296 -
accuracy: 0.9099 - recall: 0.9054 - val_loss: 0.2267 - val_accuracy: 0.9159 -
val recall: 0.9135
Epoch 20/100
477/477 [============== ] - 237s 490ms/step - loss: 0.2266 -
accuracy: 0.9135 - recall: 0.9073 - val_loss: 0.2368 - val_accuracy: 0.9062 -
val recall: 0.9008
Epoch 21/100
477/477 [============= ] - 235s 484ms/step - loss: 0.2215 -
accuracy: 0.9156 - recall: 0.9105 - val loss: 0.2575 - val accuracy: 0.9044 -
val_recall: 0.9032
Epoch 22/100
accuracy: 0.9225 - recall: 0.9186 - val_loss: 0.2236 - val_accuracy: 0.9171 -
val_recall: 0.9153
Epoch 23/100
477/477 [============= ] - 235s 487ms/step - loss: 0.2054 -
accuracy: 0.9212 - recall: 0.9167 - val_loss: 0.2259 - val_accuracy: 0.9153 -
val recall: 0.9135
Epoch 24/100
accuracy: 0.9220 - recall: 0.9174 - val_loss: 0.2139 - val_accuracy: 0.9255 -
val_recall: 0.9231
Epoch 25/100
477/477 [============= ] - 237s 490ms/step - loss: 0.2040 -
accuracy: 0.9224 - recall: 0.9182 - val_loss: 0.2990 - val_accuracy: 0.8936 -
val_recall: 0.8894
Epoch 26/100
477/477 [============= ] - 236s 488ms/step - loss: 0.1930 -
accuracy: 0.9250 - recall: 0.9208 - val_loss: 0.2213 - val_accuracy: 0.9123 -
val_recall: 0.9093
Epoch 27/100
accuracy: 0.9302 - recall: 0.9259 - val loss: 0.1991 - val accuracy: 0.9255 -
val recall: 0.9231
Epoch 28/100
accuracy: 0.9247 - recall: 0.9204 - val_loss: 0.2237 - val_accuracy: 0.9183 -
val_recall: 0.9171
Epoch 29/100
accuracy: 0.9236 - recall: 0.9205 - val_loss: 0.2041 - val_accuracy: 0.9189 -
val_recall: 0.9171
Epoch 30/100
accuracy: 0.9316 - recall: 0.9283 - val_loss: 0.2111 - val_accuracy: 0.9231 -
val_recall: 0.9219
```

```
Epoch 31/100
    477/477 [============= ] - 235s 486ms/step - loss: 0.1753 -
    accuracy: 0.9264 - recall: 0.9236 - val_loss: 0.1969 - val_accuracy: 0.9327 -
    val recall: 0.9309
    Epoch 32/100
    accuracy: 0.9321 - recall: 0.9294 - val_loss: 0.2105 - val_accuracy: 0.9243 -
    val_recall: 0.9219
    Epoch 33/100
    477/477 [============= ] - 239s 494ms/step - loss: 0.1785 -
    accuracy: 0.9370 - recall: 0.9337 - val loss: 0.2645 - val accuracy: 0.9038 -
    val_recall: 0.9002
    Epoch 34/100
    accuracy: 0.9300 - recall: 0.9274 - val_loss: 0.2259 - val_accuracy: 0.9153 -
    val recall: 0.9135
    Epoch 35/100
    477/477 [============= ] - 238s 492ms/step - loss: 0.1689 -
    accuracy: 0.9348 - recall: 0.9310 - val_loss: 0.2165 - val_accuracy: 0.9195 -
    val recall: 0.9159
    Epoch 36/100
    accuracy: 0.9361 - recall: 0.9322 - val_loss: 0.2236 - val_accuracy: 0.9171 -
    val_recall: 0.9135
    Epoch 37/100
    477/477 [============= ] - 239s 495ms/step - loss: 0.1687 -
    accuracy: 0.9353 - recall: 0.9318 - val_loss: 0.2914 - val_accuracy: 0.8942 -
    val_recall: 0.8906
    Epoch 38/100
    accuracy: 0.9324 - recall: 0.9297 - val_loss: 0.3107 - val_accuracy: 0.8996 -
    val_recall: 0.8978
    Epoch 39/100
    accuracy: 0.9381 - recall: 0.9361 - val loss: 0.2609 - val accuracy: 0.9087 -
    val recall: 0.9056
    Epoch 40/100
    accuracy: 0.9352 - recall: 0.9333 - val_loss: 0.2308 - val_accuracy: 0.9111 -
    val_recall: 0.9105
    Epoch 41/100
    477/477 [============= ] - 239s 495ms/step - loss: 0.1488 -
    accuracy: 0.9416 - recall: 0.9391 - val_loss: 0.2395 - val_accuracy: 0.9117 -
    val_recall: 0.9093
[14]: transfer_model.save("./

-- tranferlearning_densenet169_with_balanced_focal_loss_3_class.h5")
```

```
def plot_metrics(history,metrics=[]): #retorna una lista de tuplas
    fig,axes=plt.subplots(1,len(metrics))
    fig.set_size_inches(15,5)
    graph=pd.DataFrame(history)
    for i,ax in enumerate(axes.flat):
        graph[list(metrics[i])].plot(kind="line",style="-",ax=ax)
        ax.set_title(" VS ".join(list(metrics[i])))
        ax.grid(True)
    plt.show()
```

[16]: metrics=[("accuracy","val_accuracy"),("recall","val_recall"),("loss","val_loss")]
 plot_metrics(history_model.history,metrics=metrics)




El modelo se entreno en 41 Epochs

• El entrenamiento del modelo se detuvo en 47 epochs lo que nos dice que la funcion de perdida en la data de validacion no mejoro por 10 epochs consecutivos, probablemente, ya no mejore para futuras epocas.

Ahora veamos el rendimiento del modelo base en los datos de entrenamiento y validacion

```
accuracy: 0.9339 - recall: 0.9321
[19]: [0.19431829452514648, 0.93388432264328, 0.9321133494377136]
        • Mostramos la matriz de confusion en los datos de entrenamiento y validacion
     Para el conjunto de entrenamiento
[20]: y_true=train_generator.classes
      predictions=transfer_model.predict(train_generator)
      y_pred=np.argmax(predictions,axis=1)
[21]: print("Indices de clase")
      for idx,clase in train_generator.class_indices.items():
          print(idx,":",clase)
     Indices de clase
     COVID : 0
     Enfermedades Pulmonares No COVID19 : 1
     Normal: 2
[22]: #obtenemos la matriz de confusion de sklearn
      from sklearn.metrics import confusion_matrix
      import seaborn as sns; sns.set()
      classes=train_generator.class_indices.keys()
      mat_train=confusion_matrix(y_true,y_pred)
      sns.heatmap(mat_train,square=True,annot=True,fmt="0.
       →2f",cmap="coolwarm",xticklabels=classes,yticklabels=classes)
      plt.xticks(rotation=60)
      plt.title("Matriz de confusion en los datos de entrenamiento")
      plt.show()
```



• Reporte de clasificacion para el conjunto de entrenamiento

[23]: report=classification_report(y_true,y_pred,target_names=list(train_generator.

--class_indices.keys()))
print(report)


	precision	recall	f1-score	support
	•			
COVID	0.17	0.18	0.17	2604
Enfermedades Pulmonares No COVID19	0.34	0.35	0.35	5296
Normal	0.48	0.46	0.47	7338
accuracy			0.37	15238
macro avg	0.33	0.33	0.33	15238
weighted avg	0.38	0.37	0.38	15238

• Para el conjunto de validacion

```
[24]: y_true=validation_generator.classes predictions=transfer_model.predict(validation_generator) y_pred=np.argmax(predictions,axis=1)
```

```
[25]: classes=validation_generator.class_indices.keys()
mat_val=confusion_matrix(y_true,y_pred)
sns.heatmap(mat_val,square=True,annot=True,fmt="0.

→2f",cmap="coolwarm",xticklabels=classes,yticklabels=classes)
plt.xticks(rotation=60)
plt.title("Matriz de confusion en los datos de Validacion")
plt.show()
```



• Reporte de clasificación para los datos de validación

```
[26]: report=classification_report(y_true,y_pred,target_names=list(train_generator.

→class_indices.keys()))
print(report)
```

	precision	recall	f1-score	support
	_			
COVID	0.17	0.17	0.17	289
Enfermedades Pulmonares No COVID19	0.37	0.36	0.36	589
Normal	0.49	0.50	0.50	816
accuracy			0.39	1694
macro avg	0.34	0.34	0.34	1694
weighted avg	0.39	0.39	0.39	1694

1.0.1 RESULTADOS FINALES: MODELO TRANFER LEARNING CON PENAL-IZACION DE PESOS PARA EL BALANCEO DE CLASES. USANDO 3 CLASES

- El modelo base ha obtenido un puntaje de accuracy ACC=94.21% y recall RE-CALL=93.87% en el conjunto de entrenamiento.
- El modelo ha obtendio un puntaje de accuracy ACC=93.39% y recall RECALL=93.21% en el conjunto de validacion.

IMPORTANTE: El modelo ha alcanzado equilibrio entre los datos de entrenamiento y validacion, lo que significa que es un modelo final con aproximadamente 93% de precision. Este modelo pasará a la Fase de evaluación del modelo.